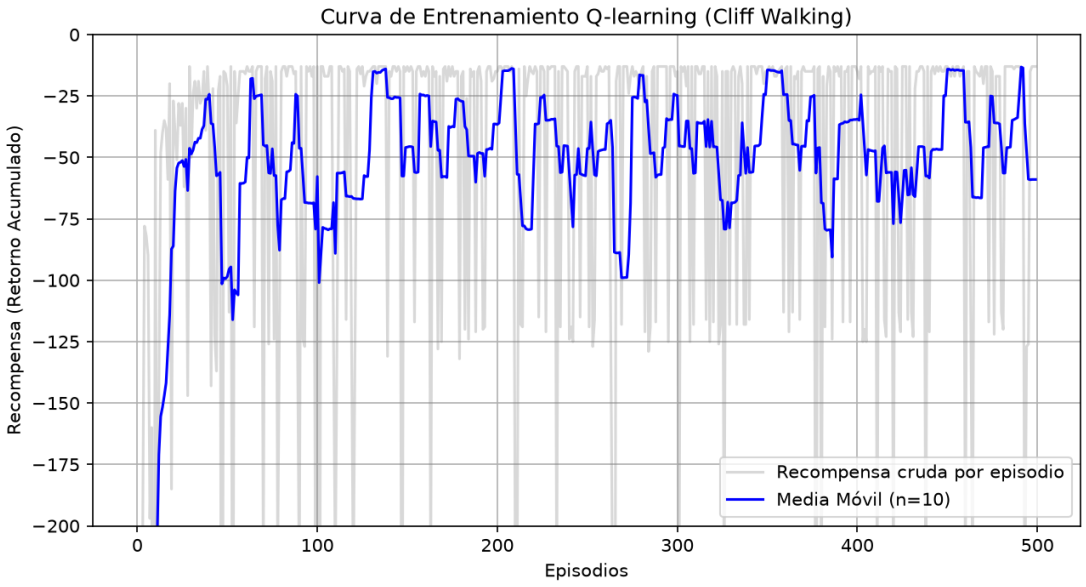
Capturas de evidencia

Capturas de la terminal y ejecución del cliff_walking.py con la política greedy

```
GaeloZero1@DESKTOP-IRVQH1G MINGW64 /e/Programación/IA/inteligencia-artificial/Q-learning/ejercicios/
solucion-01 (main)
$ python cliff_walking.py
Semilla utilizada: 42
Retorno de la política greedy óptima: -13
Número de pasos S -> G: 13

Cuadrícula de la política greedy (Flechas):
↓  ↑  ←  →  →  ↑  →  ↓  ↓  ↓  →  ↓
→  →  ↓  ↓  →  ↓  →  →  →  ↓  ↓  ↓
→  →  →  →  →  →  →  →  →  →  →  ↓
S  C  C  C  C  C  C  C  C  C  C  G
```

Gráfica de la recompensa por episodio de los 500 episodios



Reporte

¿Por qué el camino de 13 pasos, pegado al acantilado, es óptimo?

Dado este entorno, el objetivo a alcanzar es la maximización del retorno acumulado. Ya que cada transición ordinaria impone una penalización de -1, la optimización matemática resultante equivale poder hallar la ruta más corta hacia la meta (G). El camino que se encuentra pegado al borde consta de 13 pasos (1 hacia el norte, 11 hacia el este y 1 hacia el sur), dando como resultado un retorno de -13. Si se tomase otra ruta o desvío que pueda considerarse "seguro" por las filas superiores, ocasionaría un aumento en la longitud de la ruta, obteniendo un costo de -15 o -17 puntos. Dado a que el algoritmo Q-learning puro en fase de explotación tiene como fin ignorar los riegos y hallar la ruta más corta absoluta, el camino puede realizarse con 13 pasos de forma optimizada.

¿Por qué la curva de entrenamiento queda por debajo de −13 aunque la política greedy ya sea óptima?

Esto es ocasionado a que, durante la fase de entrenamiento, el comportamiento que toma el agente se dicta por la política ϵ-greedy (donde $\epsilon = 0.1$), lo cual significa que en el 10% de los movimientos que este realiza, el agente puede elegir una acción o ruta aleatoria que desarrolla su estado de exploración. Debido a que la ruta óptima transcurre justo al lado del abismo, puede existir el caso o situación en la cual la probabilidad de que la exploración aleatoria resulte en un paso hacia el sur, lo cual provocaría la caída en un acantilado, de tal forma que se obtiene la penalización masiva de -100, al ocurrir esto de manera frecuente, cada caída exploratoria continua promedian el retorno por episodio fuertemente a la baja, impidiendo que la curva de entrenamiento pueda converger en el puntaje perfecto, ósea -13.

En el paso que cae al acantilado, ¿cuál es s' en el backup de Q-learning, y por qué ese backup no trata el acantilado como estado terminal?

Al momento de caer en el acantilado, el siguiente estado s' evaluado por el entorno se toma como el estado inicial S. Este backup no toma a la caída como un estado terminal, esto debido a que las reglas del entorno indican que al momento en el que el agente cae no se finaliza la búsqueda de la meta, de esta forma el episodio puede continuar y solamente se teletransporta al agente nuevamente al inicio con la fuerte penalización. Ya que no resulta en una acción terminal, la ecuación de actualización considera el valor futuro, suma el término ponderado $max_a, Q(S, a')$, en lugar de colapsarlo a 0, tal y como termina sucediendo al entrar a la meta G.